Извлечение медицинских данных из электронных медицинских карт с помощью алгоритмов обработки естественного языка

Александр В. Гусев, Роман Е. Новицкий, Александр А. Ившин, Юлия С. Болдина, Алексей С. Штыков, Алексей С. Васильев.

А. В. Гусев и Р. Е. Новицкий: ООО «К-Скай», Россия, Республика Карелия, Петрозаводск, наб. Варкауса, 17, помещение 20, 185031. Остальные авторы: Петрозаводский государственный университет, Россия, Республика Карелия, Петрозаводск, пр. Ленина, 33, 185910.

Электронная почта: agusev@webiomed.ai; roman@webiomed.ai; scipeople@mail.ru; juliaisakova-20@mail.ru; shtykoff@petrsu.ru; alvas@petrsu.ru.

Благодарности. Исследование выполнено при финансовой поддержке Министерства науки и высшего образования Российской Федерации, тема № 075-15-2021-665. В работе использована уникальная научная установка «Многокомпонентный программно-аппаратный комплекс для автоматизированного сбора, хранения, разметки исследовательских и клинических биомедицинских данных, их унификации и анализа на базе центра обработки данных с технологиями искусственного интеллекта» (регистрационный номер 2075518).

Аннотация. Развитие методов искусственного интеллекта в медицине требует доступности больших объёмов исходных данных. Источником таких данных служат электронные медицинские карты. Извлечение информации из них сопровождается рядом трудностей, преимущественно связанных с произвольной формой заполнения и использованием врачами различных сокращений. В статье описан метод обработки электронных медицинских карт, позволяющий извлекать информацию, необходимую для построения алгоритмов работы программных комплексов искусственного интеллекта и их обучения. Метод разработан и апробирован на медицинских картах, заполненных на русском языке. Для работы с документами на других языках специальная адаптация не требуется: достаточно изменить обучающие данные и полностью переобучить все модели.

Ключевые слова: электронная медицинская карта, искусственный интеллект, пациент, прогнозирование развития заболеваний, машинное обучение.

Примечание переводчика. Это перевод предоставленной статьи, а не обновлённый обзор технологий. Утверждения о состоянии программных библиотек и достигнутых результатах относятся к оригиналу. EMR и EHR далее передаются общим термином «электронная медицинская карта» (ЭМК), если различие несущественно. Код сохранён в исходном виде; неоднозначности оригинала отмечены отдельно.

1. Введение

Для диагностики и прогнозирования развития заболеваний в медицине всё чаще применяют методы машинного обучения (ML) как часть искусственного интеллекта (ИИ). Их использование требует большого количества медицинских данных, называемых Big Data. Такие данные можно получить в проспективных исследованиях, например во Фрамингемском исследовании сердца (FHS), продолжающемся 70 лет. FHS стало первым крупным когортным исследованием с длительным наблюдением, посвящённым эпидемиологии сердечно-сосудистых заболеваний в США. В настоящее время оно охватывает несколько поколений населения Фрамингема.

Подобные исследования требуют значительных затрат времени, труда и средств. Потребность в финансировании медицинских исследований ежегодно растёт, поэтому востребованы новые, менее дорогие способы получения данных. Один из них - извлечение информации из уже существующих медицинских документов, включая электронные медицинские карты (EMR) и

электронные записи о здоровье (EHR). Сегодня имеется большое количество таких документов. С одной стороны, изучение их содержимого врачом требует значительных затрат времени и средств. С другой стороны, алгоритмы извлечения медицинских данных и фактов делают эту задачу перспективной и повышают доступность содержащейся в документах клинической информации. EMR и EHR содержат достаточно полные сведения для успешного прогнозирования медицинских событий (Malmasi et al., 2019).

Обработка естественного языка (NLP) - раздел ИИ, связанный с интеллектуальной обработкой человеческого языка. Сейчас существует множество фреймворков и библиотек, решающих общие языковые задачи. Например, модели анализа текста обучают на газетных статьях или научных публикациях. Это объясняет многочисленные ошибки и неточности при применении NLP к медицинским документам. Дополнительные сложности создают медицинская тематика, особенности документов и сокращения, используемые врачами. При обработке свободного текста ЭМК нередко приходится разрабатывать или адаптировать NLP-инструмент для каждой медицинской базы данных и даже для каждого клинического события. Это трудоёмко: инструменты необходимо проверять на значительных объёмах текста, предварительно размеченного экспертами.

Современные методы машинного обучения моделируют временную последовательность структурированных событий из клинической истории пациента с помощью свёрточных и рекуррентных нейронных сетей, чтобы прогнозировать будущие события, связанные со здоровьем. Существуют и другие подходы, извлекающие знания из данных посредством интеллектуального анализа на основе онтологии предметной области. Извлечение медицинских данных на русском языке затруднено отсутствием необходимого программного обеспечения и размеченных медицинских корпусов. Для применения ИИ в медицине нужны «большие медицинские данные», а для их получения - алгоритмы извлечения информации из медицинских документов.

Повторное использование медицинских данных, извлечённых из ЭМК, появилось относительно недавно и стало востребованным прежде всего при подготовке данных для обучения алгоритмов ИИ. Одна из проблем применения этого подхода в России заключается в том, что медицинские тексты, включая ЭМК, написаны по-русски. Доступные решения разрабатываются главным образом для английского языка и в небольшом количестве - для немецкого, французского и китайского. Перевод ЭМК с русского на английский не решил бы проблему, поскольку в России используется другая система клинических рекомендаций. Клинические рекомендации - документ, основанный на подтверждённом клиническом опыте профилактики, диагностики, лечения и реабилитации. Они включают модели пациентов, последовательность действий медицинского работника, схемы диагностики и лечения, осложнения, сопутствующие заболевания и другие факторы, влияющие на результаты лечения. Для английского языка существует множество NLP-библиотек и несколько медицинских корпусов. В частности, пакет Python scispaCy содержит модели обработки биомедицинских, научных и клинических текстов.

Главная трудность, сдерживающая применение технологий ИИ в медицине, - сложность извлечения данных из медицинских записей. Особенно остро она проявляется при работе с русскоязычными ЭМК. Поэтому рассматриваемая в статье тема исследования актуальна.

2. Обзор литературы

ЭМК обычно содержат разнообразную медицинскую информацию как в структурированном виде, так и в форме произвольного текста. Редко удаётся ограничиться одним методом извлечения информации. В системе Webiomed одновременно применяются методы на основе правил, классификация с помощью машинного обучения и распознавание именованных сущностей (NER) средствами NLP (Gavrilov et al., 2020).

Наиболее распространённые алгоритмы машинного обучения для классификации текстов: семейство наивных байесовских алгоритмов, метод опорных векторов и глубокое обучение.

Наивный байесовский классификатор - один из базовых алгоритмов классификации. Однако он часто работает не хуже, а иногда лучше более сложных алгоритмов. Его преимущество - небольшой объём данных, необходимый для обучения, оценки параметров и классификации. Все параметры модели можно приближённо оценить по относительным частотам в обучающей выборке. Такие оценки являются оценками максимального правдоподобия вероятностей.

Метод опорных векторов (SVM). Текст раздела «Жалобы» часто содержит «шум», способный снижать точность классификации с помощью SVM.

Преимущества SVM:
- хорошо работает с большим пространством признаков;
- хорошо справляется с небольшими объёмами данных;
- максимизирует разделяющую полосу, которая, подобно «подушке безопасности», уменьшает число ошибок классификации;
- задача имеет единственное решение: при определённых гиперпараметрах разделяющая гиперплоскость единственна, поскольку алгоритм сводится к решению задачи квадратичного программирования в выпуклой области.

Недостатки SVM:
- длительное обучение на больших наборах данных;
- чувствительность к шуму: выбросы в обучающих данных становятся опорными объектами и непосредственно влияют на построение разделяющей гиперплоскости;
- отсутствует общий способ построения ядер и пространств преобразования, наиболее подходящих для конкретной задачи при линейной неразделимости классов. Выбор полезных преобразований данных остаётся искусством.

Гибридные системы объединяют все или большинство рассмотренных принципов и последовательно применяют основанные на них классификаторы.

В отличие от методов на основе правил, при обработке текстовых данных слова необходимо преобразовать в векторное представление. Универсальных рекомендаций по выбору метода классификации и векторизации для конкретной информации нет. В каждом случае приходится проверять, какая комбинация методов даёт лучший результат.

Медицинские тексты трудно обрабатывать без учёта языковой структуры: необходимо анализировать предложения, существенные или идентифицирующие связи между их объектами и синтаксическую структуру. Для английского языка разработано множество методов и готовых инструментов. Для русского языка готовых решений меньше, и многие из них коммерческие.

Получение наборов данных из ЭМК для исследований COVID-19 рассматривается, например, в работе Pedrera-Jiménez et al. (2021). Она показала эффективность повторного использования ЭМК в больнице третичного уровня во время пандемии. Согласно исследованию Metlay et al. (2021), извлечение из ЭМК сведений о пациентах, проживающих в одном домохозяйстве, оказалось столь же эффективным для отслеживания передачи инфекции, как отслеживание контактов при COVID-19. Кроме того, аналитические методы не всегда дают результаты в реальном времени, поэтому данные ЭМК легко упустить или использовать не полностью. В целом они могут поддерживать борьбу с COVID-19 при наличии инфраструктуры и методов для масштабирования такого подхода.

Ошибки извлечения данных из ЭМК могут объясняться следующими проблемами:
- многочисленные орфографические ошибки;
- сокращения, специфичные для конкретного медицинского учреждения;
- несогласованные предложения, построенные с нарушением языковых правил.

Результаты автоматического извлечения информации можно улучшить, применяя автоматическую коррекцию орфографии, совершенствуя словари для словарных методов и обучающие выборки для методов машинного обучения (Meystre et al., 2008).

Вместо вручную созданных правил классификация текста с помощью машинного обучения решает задачу на основе размеченного обучающего набора. Используя заранее размеченные примеры для обучения и валидации, алгоритм выявляет связи между фрагментами текста и определённым заключением или диагнозом, ожидаемым для данного входа, например текста жалоб. Для применения классификатора необходимо выделить признаки машинного обучения: преобразовать каждый текст в числовое векторное представление.

Результаты классификации можно улучшить с помощью бустинга. Это процедура последовательного построения композиции алгоритмов машинного обучения, в которой каждый следующий алгоритм стремится компенсировать недостатки всех предыдущих. Бустинг является алгоритмом оптимизации при построении такой композиции. Изначально понятие возникло в работах по вероятностно корректному обучению, рассматривавших вопрос, можно ли получить хороший алгоритм из нескольких слабых, лишь немного превосходящих случайный выбор (Mayr et al., 2014).

В течение последних десяти лет бустинг остаётся одним из наиболее популярных методов машинного обучения наряду с нейронными сетями и методом опорных векторов. Основные причины - простота, универсальность, гибкость, возможность создания различных модификаций и, прежде всего, высокая обобщающая способность.

Бустинг над деревьями решений считается одним из наиболее эффективных методов классификации. Во многих экспериментах по мере роста композиции частота ошибок на независимой тестовой выборке снижалась почти без ограничений. Более того, качество на тестовой выборке часто продолжало улучшаться даже после достижения безошибочного распознавания всей обучающей выборки. Это изменило устоявшееся представление о том, что для повышения обобщающей способности обязательно ограничивать сложность алгоритмов.

Интерес представляет открытый пакет обработки естественного языка spaCy. Он написан на Python и выполняет токенизацию, разметку частей речи (PoS) и синтаксический анализ зависимостей. В статье он характеризуется как самый быстрый доступный NLP-парсер с современной точностью. Обучение описано на странице «Обучение статистических моделей spaCy»: https://spacy.io/usage/training.

В упоминаемой авторами масштабной оценке существующих парсеров зависимостей сравнивались точность и скорость десяти готовых инструментов. Показатель LAS, оценивающий правильность присоединения зависимостей с учётом меток, составлял 85-90%. Хотя spaCy не оказался самым точным, он был самым быстрым при сопоставимой точности. [Примечание переводчика: ссылка на авторов этой оценки в соответствующем предложении оригинала отсутствует.]

Модели spaCy статистические: каждое решение о части речи слова или его принадлежности к именованной сущности представляет собой прогноз, основанный на обучающих примерах. Для обучения нужны тексты и разметка, которую модель должна предсказывать: часть речи, именованная сущность или другая информация. Этот пакет также используется в моделях распознавания медицинских сущностей (Amogh et al., 2020).

Согласно оригиналу, spaCy не предоставляет предобученную модель для русского языка, но позволяет обучить её самостоятельно. В spaCy 2.0 представлены новые нейронные модели для разметки, синтаксического анализа и распознавания сущностей (Honnibal & Johnson, 2015).

3. Материалы и методы

Цель работы - разработать решение, позволяющее извлекать конкретные данные из ЭМК с использованием технологий искусственного интеллекта.

В ходе исследования решены следующие задачи:
- изучить характер данных, содержащихся в ЭМК;
- определить наборы данных, необходимые для построения прогностических моделей течения заболеваний;
- выбрать методы структурирования и извлечения данных с учётом целей информационного поиска и удобства дальнейшего использования;
- разработать и проверить прогностическую модель, выявляющую связи между извлечёнными данными и прогнозирующую на их основе развитие медицинских событий.

Для достижения цели применялись поиск научно-технической и медицинской информации по теме, анализ и систематизация собранного материала, а также сравнительный метод, позволивший выбрать наиболее подходящие способы решения задачи.

Исследование проводилось на обезличенных медицинских данных пациентов трёх российских больниц. Использованы сведения о пациентах 18-70 лет с сердечно-сосудистыми заболеваниями, собранные лечащими врачами во время первого очного посещения медицинского учреждения. Записи составлялись разными врачами в свободной форме и представляли собой неструктурированный текст.

Извлекались следующие сведения: пол, возраст, рост, вес, артериальное давление (систолическое и диастолическое), частота дыхания, частота сердечных сокращений, симптомы COVID-19, вредные привычки (курение и злоупотребление алкоголем), ранее установленные диагнозы по МКБ-10, жалобы пациента, результаты врачебного осмотра и наличие сердечно-сосудистых заболеваний у родителей. Также учитывались рекомендации врачей и назначенная лекарственная терапия.

Использовались медицинские записи, внесённые в ЭМК на русском языке. Пример представлен в таблице 1.

Таблица 1. Пример записи в российской ЭМК

Общие сведения: женщина, 48 лет.

Диагнозы по МКБ-10: F20.0, K02.1, I10, M42.1, N95.1, D10.4, D27.

Объективно: общее состояние удовлетворительное, эмоционально лабильна. Кожные покровы чистые, обычной окраски. «Периферические не работают». Зев розовый, чистый. Тоны сердца ритмичные. АД 130/80 мм рт. ст. Пульс 65 ударов в минуту. В лёгких дыхание везикулярное. Перкуторно лёгочный звук. Живот мягкий, б/б при пальпации. «Печень, селезёнка не отведены». Т - 36,5. Физиологические отправления в норме. Пастозность стоп. Курение в течение 15 лет.

Источник: составлено авторами. Примечание переводчика: в английском тексте этого примера имеются неясные фразы «Peripherals don't work» и «Liver, spleen not taken away». Они переданы буквально в кавычках; достоверно восстановить исходные русские записи невозможно. «The pasty stop» по контексту передано как «пастозность стоп».

Данные выгружены в виде текстового файла из системы поддержки принятия клинических решений (СППКР) Webiomed, содержащей более 50 млн записей (Gavrilov et al., 2020).

4. Результаты и обсуждение

Чтобы модель ИИ начала выдавать точные прогнозы, её необходимо обучить. Для обучения требуется множество примеров, извлечённых из ЭМК. Это обусловило необходимость изучения характера содержащихся в них данных.

Установлено, что основные трудности автоматического извлечения данных связаны с использованием медицинскими работниками собственных сокращений и кратких форм записи, орфографическими ошибками, несогласованным изложением результатов осмотра и жалоб, нарушением грамматики в описательных предложениях и небрежным заполнением полей ЭМК.

На следующем этапе авторы выбрали методы, лучше всего подходящие для структурирования и извлечения данных с учётом целей поиска и удобства дальнейшего использования.

Выяснилось, что необходимо одновременно применять несколько методов: ни один из существующих подходов не удовлетворяет полностью потребности обработки ЭМК, содержащих структурированную информацию и свободный текст. Данные и методы их извлечения представлены в таблице 2. В Webiomed совместно используются правила, классификация с помощью машинного обучения и распознавание именованных сущностей.

Таблица 2. Методы NLP при работе с ЭМК

Категория	Форма и разделы данных	Методы и примеры
Текущая проблема	Структурированные или полуструктурированные данные в заданных разделах: подробное описание проблем, перечень симптомов, психический статус	NER, правила и гибридные методы для описания проблем; классификация текста для симптомов; NER для психического статуса. Извлекаются актуальные диагнозы, симптомы, результаты физикального осмотра и исследований. Для «боли в груди» выявляются фрагменты, где слово, описывающее боль (например, давление), предшествует слову локализации (например, грудь) или следует за ним.
Клинические записи	Неструктурированный текст: записи о динамике состояния, консультативные заключения, дополнительные больничные записи, история лечения	NER и методы на основе правил для записей и заключений; NER для истории предшествующего лечения.
Личный анамнез	Структурированные или полуструктурированные разделы: этапы развития, медицинский анамнез, физическое, эмоциональное и сексуальное насилие, питание, физическая активность	NLP: извлечение диагнозов. Примеры: история заболеваний, операций, развития и социальный анамнез.
История употребления психоактивных веществ	Неструктурированные данные: начало употребления, частота, количество, предпочитаемые вещества и привычки, алкоголь, курение	NLP: извлечение информации; методы машинного обучения.
Семейный анамнез	Неструктурированные данные: возраст и здоровье родителей, братьев и сестёр; родственные связи; культурные и этнические факторы; история заболеваний, включая психические	NLP: извлечение данных; методы на основе правил. Пример: история заболеваний членов семьи.
Работа и образование	Неструктурированные данные: история обучения и занятости, достижения, закономерности и проблемы	Конкретные методы и примеры в соответствующей строке оригинала не указаны.
Лабораторные исследования	Структурированные или полуструктурированные разделы: интерпретация лабораторных, радиологических, патоморфологических и других исследований	NLP, NER; данные лабораторных исследований.
Прочие данные визуализации и сканированные документы	Эхокардиография, электрокардиография, КТ, МРТ, медицинские документы из внешних источников	NLP, аннотирование.

Источник: составлено авторами. Примечание переводчика: для читаемости многоуровневые ячейки исходной таблицы объединены; состав сведений сохранён.

Использование системы машинного обучения на основе правил требует специальной разметки текста. Выделенные при разметке фрагменты используются ИИ для выявления связей между ними, в частности между жалобами пациента, результатами анализов и осмотра и последующим подтверждённым диагнозом. Метод требует преобразования каждого символа текстовой записи в числовое векторное представление, доступное для обработки программным комплексом. [Примечание переводчика: формулировка «система машинного обучения на основе правил» сохранена по оригиналу, хотя далее описывается обучение по размеченным данным.]

Применялся метод «мешок слов», в котором вектор отражает частоту слов из заранее определённого словаря. Алгоритм получает обучающие пары: набор признаков (вектор каждого текста) и метку (диагноз), чтобы построить классификационную модель. На вопрос, сколько данных достаточно, универсального ответа нет: это зависит от задачи машинного обучения. В данном исследовании использовалось правило: 100 предложений с одним признаком для обучения и 30 для валидации.

Для классификации информации раздела «Жалобы» использована следующая архитектура сети: входной слой, свёрточный слой, слой максимального пулинга, полносвязный скрытый слой, выходной слой.

Между основными слоями предусмотрены дополнительные слои dropout для защиты от переобучения. В оригинале принцип описан как «забывание» определённого процента весов, задаваемого параметром dropout. Для свёрточного и скрытого слоёв выбрана функция активации ReLU, для выходного - Softmax, которую авторы называют одним из частных случаев сигмоидальной функции для многоклассовой классификации. Для реализации выбраны Python с библиотеками работы с данными и нейронными сетями и Keras в составе TensorFlow, поддерживающий CNN, LSTM и biLSTM. [Примечание переводчика: технические описания dropout и Softmax здесь воспроизводят оригинал. Dropout обычно отключает активации нейронов, а не «забывает веса».]

Для извлечения слов из текстов преимущественно применялась технология правил и регулярных выражений. Этот метод остаётся наиболее эффективным для признаков, принимающих небольшое число значений и практически не меняющихся со временем.

В Webiomed он используется для извлечения симптомов COVID-19 из медицинских записей. Примеры приведены в таблице 3.

Таблица 3. Примеры записей для извлечения симптомов COVID-19

«Состояние крайне тяжёлое. Сознание - глубокий сопор. Положение вынужденное. Телосложение правильное. Конституция нормотермическая».

«Жалобы (со слов матери): слабость, сниженное настроение, малоподвижность, снижение аппетита: “очень похудела”, ступорозное состояние: “сидит и смотрит в одну точку, ночью не спит”. Сама пациентка подтверждает эти симптомы и указывает на наличие суицидальных мыслей».

«Онемение 2-5-го пальцев левой кисти постоянное, жжение в них. Головокружение непостоянное. Аносмия более 20 лет».

«Боль в глазах при повороте в сторону. Шум в ушах. При расспросе - снижение обоняния».

Источник: составлено авторами. Примечание переводчика: заголовок сохранён по оригиналу; приведённые записи сами по себе не подтверждают COVID-19. Фраза о «нормотермической конституции» также сохранена по исходному тексту.

Результаты классификации можно улучшить с помощью описанного выше бустинга. Для извлечения данных из ЭМК использован открытый пакет spaCy, преимущества которого рассмотрены ранее.

Команда предварительного обучения spaCy позволяет применять перенос обучения для инициализации моделей информацией из неразмеченных данных. Используется задача языкового моделирования, сходная с применяемой в системе Google BERT, относящейся к передовым NLP-технологиям (SOTA).

При обучении модель должна не только запоминать примеры, но и учиться делать выводы, которые можно обобщить на новые примеры. Этот процесс описан на странице

https://spacy.io/usage/training. Для проверки обобщающей способности нужны новые тестовые данные. Обучение с нуля требует сотен примеров для обучения и валидации. Обновление существующей модели может дать результат даже при небольшом числе примеров, если они репрезентативны.

Пример описания обучающих данных в программе Python (код оригинала):
```
TRAIN_DATA = [
("vesicular breathing, no wheezing, RR 18 in min, heart tones
clear, rhythmic, BP 130/80 mm Hg heart rate 72 beats per min.",
{'entities': [(34, 46, 'RR'), (79, 97, 'BP'), (98, 113, 'HR')]}),
... ]
```

Перевод строки: «Дыхание везикулярное, хрипов нет, ЧДД 18 в минуту, тоны сердца ясные, ритмичные, АД 130/80 мм рт. ст., ЧСС 72 удара в минуту». RR - частота дыхания, BP - артериальное давление, HR - частота сердечных сокращений. Числа в разметке задают позиции символов исходного текста; при переводе текста их необходимо вычислить заново. Переносы внутри строк в печатном оригинале не следует считать готовым исполняемым кодом.

Пример описания обучающих данных для командной строки (CLI), сохранён как фрагмент оригинала:
```
"id": 9, "paragraphs": [
{"raw": "BP 120/70 мм Hg",
"sentences": [{
"tokens": [
{"id": 0, "orth": "BP", "ner": "B-BP"},
{"id": 1, "orth": "120/70", "ner": "I-BP"},
{"id": 2, "orth": "мм", "ner": "I-BP"},
{"id": 3, "orth": "рт.ст", "ner": "L-BP"},
{"id": 4, "orth": ".", "ner": "O"}],
"brackets": []}],
"cats": []}]
```

В этом примере размечено артериальное давление 120/70 мм рт. ст. B, I и L обозначают начало, внутренний и последний токен сущности; O - токен вне сущности. Примечание переводчика: исходный фрагмент смешивает русские и английские обозначения единиц; эта особенность сохранена.

Классификация текста - одна из основных задач NLP, позволяющая определить принадлежность текста к конкретному классу. Авторы применили её для определения основного диагноза ЭМК на основе размеченных медицинских данных. Признаки раздела «Жалобы» использовались как входные переменные, а «Диагноз» - как целевая переменная. [Примечание переводчика: в оригинале признаки жалоб названы «зависимой переменной», хотя по описанию это входные признаки.]

Основные проблемы традиционной классификации текста:
1. Необходимо выбрать способ преобразования текста в вектор: для разных задач наилучшее качество дают разные методы.
2. Полученное пространство признаков имеет большую размерность и высокую разреженность.
3. Для повышения качества часто требуется удалять стоп-слова.
4. Необходимы стемминг или лемматизация, поскольку разные грамматические формы слова имеют одинаковый смысл.

При предварительной обработке текста признака «Жалобы» используется библиотека лемматизации Python PyMorphy2. Множество алгоритмов автоматической классификации текстов можно разделить на три группы: основанные на правилах, основанные на машинном обучении и гибридные.

Метрики и оценка

Для выбора подходящего метода классификации и других задач NLP применялись:
- Accuracy (доля правильных ответов): доля текстов, для которых предсказана правильная метка.
- Precision (точность): доля правильно предсказанных примеров среди всех примеров, отнесённых классификатором к данной метке.
- Recall (полнота): доля примеров, предсказанных для данной метки, среди всех примеров, которые должны были получить эту метку.
- F1: гармоническое среднее точности и полноты (Chip, 2019).

При извлечении признаков из текста существенную проблему создаёт большое количество ошибок и опечаток. ЭМК - официальный медицинский документ, подписанный врачом, поэтому вносить исправления в исходный документ нельзя. Требуется предварительная обработка входного текста с исправлением ошибок, опечаток и сокращений.

spaCy предоставляет возможности повышения точности новой модели, создаваемой с нуля. Обучение занимает много времени, поэтому количество экспериментов для поиска лучших гиперпараметров ограничено. Авторы выбрали следующие настройки оптимизации:
- начинать с размера пакета 1 и постепенно увеличивать его до максимума, определяемого объёмом данных и типом задачи;
- использовать оптимизатор Adam с фиксированной скоростью обучения;
- применять усреднённые параметры;
- использовать L2-регуляризацию;
- ограничивать L2-норму градиента значением 1;
- на малых данных начинать с высокой доли dropout и линейно уменьшать её. Этот подход получен экспериментально.

Для извлечения различных признаков из ЭМК разработан ансамбль четырёх моделей. Их назначение, признаки, методы, обучающие наборы и метрики представлены в таблице 4.

Таблица 4. Разработанные NLP-модели извлечения признаков

Модель	Назначение, признаки и метод	Обучающие данные и результаты
Objective Data	Извлечение объективных данных пациента: рост, вес, частота дыхания, частота дыхания, АД. Метод: NER.	Более 500 размеченных текстов. Precision 97,6%; Recall 99,5%; F1 98,6%.
Smoking Extract	Извлечение признака «Курение»: курит / не курит. Методы: CAR, TF-IDF, LSA.	Более 500 размеченных текстов. Precision 88,5%; Recall 96,1%; F1 92,3%.
Laboratory data	Извлечение данных лабораторных анализов: глюкоза, холестерин, креатинин, мочевина, гликемический профиль, гематокрит, триглицериды, ЛПВП, ЛПНП. Метод: NER.	Более 700 размеченных текстов. Precision 91,4%; Recall 87,2%; F1 89,2%.
Covid-19-Symptoms	Извлечение симптомов COVID-19: температура тела, кашель, одышка, ощущение заложенности в груди, миалгия, спутанность сознания, головная боль, кровохарканье, диарея, аносмия, конъюнктивит, ступор. Метод: NER.	Более 1500 размеченных текстов. Precision 83,6%; Recall 80,6%; F1 82,1%.

Источник: составлено авторами. Примечание переводчика: повтор «частота дыхания» и обозначение CAR сохранены из исходной таблицы; расшифровка CAR в статье отсутствует.

Например, модель Objective Data обучалась на более чем 500 размеченных текстах методом NER в течение 120 эпох. Использовались оптимизатор стохастического градиентного спуска (SGD) и бинарная кросс-энтропия как функция потерь. Результаты функции потерь дополнительно взвешивались с учётом соотношения положительных и отрицательных примеров.

Модели можно получить двумя способами: с помощью программы на Python или командной строки. Авторы утверждают, что программный способ значительно проигрывает по времени обучения из-за использования интерпретатора, а способ командной строки использует программу на C с GPU. [Примечание переводчика: это объяснение воспроизведено из оригинала; само по себе различие интерфейсов Python и CLI не доказывает такую разницу в скорости.]

Для обучения моделей применялась команда spaCy train. Scorer и nlp.evaluate сообщают показатели классификации текста: F-меру для положительной метки в бинарных взаимоисключающих задачах и макроусреднённую F-меру для всех взаимоисключающих признаков. Большинство токенов реальных медицинских документов не входят в названия сущностей в обычном понимании. Поэтому базовые значения precision, recall и F1 чрезвычайно высоки, обычно превышают 90%; полученные значения этих метрик для сущностей авторы оценивают как достаточно хорошие.

5. Заключение

Результатом работы по извлечению признаков из ЭМК стало создание промышленной системы, встроенной в СППКР Webiomed (https://webiomed.ai). За один месяц обработано более 600 000 электронных медицинских карт и извлечено более 45 млн признаков. Благодаря этому стало возможно формировать наборы для прогностических моделей не на основе доступных зарубежных данных, а на данных населения страны применения модели - России. По утверждению авторов, это позволило существенно повысить точность прогнозирования.

На наборе из 3521 пациента с 24 признаками обучена модель прогнозирования госпитализации в течение 12 месяцев для пациентов 18-70 лет с сердечно-сосудистыми заболеваниями.

На тестовых данных получены Accuracy = 83% и AUC = 0,89. Качество характеризуется двумя показателями: частотой ложных тревог (доля ложноположительных результатов среди отрицательных примеров) и частотой обнаружения (доля истинноположительных результатов среди положительных примеров). Для бинарной классификации оценка по этим показателям обычно представляется ROC-кривой, показывающей зависимость частоты обнаружения от частоты ложных тревог при разных порогах.

Предложенный метод извлечения структурированных и неструктурированных данных из русскоязычных медицинских документов позволяет создавать наборы для моделей машинного обучения, решающих медицинские задачи, и, что особенно важно, формировать данные местного населения для более точного моделирования.

Литература

Названия работ переведены; имена авторов, названия изданий и идентификаторы сохранены для поиска источников.

1. Amogh, K. T., Tiwari, A., Dhaimodker, V. N., Rebelo, P., Desai, R., Rao, D. Модели распознавания медицинских именованных сущностей с предварительным обучением языковой модели. First Health Search and Data Mining Workshop (HSDM 2020), 2020. DOI: 10.48550/arXiv.1910.11241.

2. Chip, H. Метрики оценки языкового моделирования. The Gradient, 2019. https://thegradient.pub/understanding-evaluation-metrics-for-language-models/.

3. Gavrilov, D., Gusev, A., Korsakov, I., Novitsky, R., Serova, L. Метод извлечения признаков из электронных медицинских карт в России. Proceedings of the FRUCT’26, 2020, с. 497-500.

4. Honnibal, M., Johnson, M. Усовершенствованная немонотонная система переходов для синтаксического анализа зависимостей. Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing, 2015, с. 1373-1378.

5. Malmasi, S., Ge, W., Hosomura, N., Turchin, A. Сравнение методов обработки естественного языка при анализе разреженных клинических данных: отказ пациентов от инсулина. AMIA Joint Summits on Translational Science, 6, 2019, с. 610-619.

6. Mayr, A., Binder, H., Gefeller, O., Schmid, M. Эволюция алгоритмов бустинга: от машинного обучения к статистическому моделированию. Methods of Information in Medicine, 53(4), 2014, с. 419-427. DOI: 10.3414/ME13-01-0122.

7. Metlay, J. P., Haas, J. S., Soltoff, A. E., Armstrong, K. A. Передача SARS-CoV-2 внутри домохозяйств. JAMA Network Open, 4(2), 2021. DOI: 10.1001/jamanetworkopen.2021.0304.

8. Meystre, S. M., Savova, G. K., Kipper-Schuler, K. C., Hurdle, J. F. Извлечение информации из текстовых документов электронной медицинской карты: обзор последних исследований. Yearbook of Medical Informatics, 2008, с. 128-144. https://pubmed.ncbi.nlm.nih.gov/18660887/.

9. Pedrera-Jiménez, M., García-Barrio, N., Cruz-Rojo, J., Terriza-Torres, A. I., López-Jiménez, E. A., Calvo-Boyero, F., Jiménez-Cerezo, M. J., Blanco-Martínez, A. J., Roig-Domínguez, G., Cruz-Bermúdez, J. L., Bernal-Sobrino, J. L., Serrano-Balazote, P., Muñoz-Carrero, A. Быстрое получение наборов данных из ЭМК для исследований COVID-19: гибкая методология на основе подробных клинических моделей. Journal of Biomedical Informatics, 115, 2021, статья 103697. DOI: 10.1016/j.jbi.2021.103697.

Основной раздел статьи: I. Дополнительные разделы: IN, FS. Исходная публикация: AD ALTA: Journal of Interdisciplinary Research, с. 314-319.